Projet de fin de module : détection des maladies des cultures par CNN

Module Deep Learning · Énoncé étudiants

Groupes de 2 à 3 étudiants. Rendu au plus tard le 10/11/2026.

1. Contexte et mission

Une coopérative agricole souhaite fournir à ses agriculteurs un outil simple : photographier une feuille avec un smartphone et obtenir un diagnostic préliminaire de la maladie. Vous êtes l'équipe chargée de concevoir et évaluer le prototype d'un classifieur basé sur des réseaux de neurones convolutifs (CNN).

Le défi principal de ce projet n'est pas d'obtenir 99 % sur un jeu de données propre. C'est de répondre à la question suivante : **comment construire un modèle qui fonctionne vraiment dans un champ ?**

Remarque : le transfer learning (modèles pré-entraînés) n'a pas été abordé en cours, faute de temps. Il n'est donc pas exigé dans ce projet, qui repose sur les architectures vues en cours : MLP et CNN. Les groupes à l'aise peuvent l'explorer en bonus.

2. Le fossé laboratoire / terrain

Deux jeux de données serviront de fil rouge :

Jeu de données	Contenu	Taille approximative	Particularité
PlantVillage	Feuilles photographiées en laboratoire, fond uniforme	environ 54 000 images	Les modèles dépassent facilement 98 %
PlantDoc	Photos prises en conditions réelles (fonds chargés, lumière variable, feuilles partielles)	environ 2 500 images	Petit et difficile

Vous allez constater qu'un modèle excellent sur PlantVillage peut s'effondrer sur des photos de terrain. Comprendre, mesurer et réduire cet écart est le cœur du projet.

3. Travail demandé

Étape 1 : Cadrage et fiche d'impact (1 page)

Avant de coder, répondez par écrit aux questions suivantes :

- Qui est l'utilisateur final et dans quelles conditions prend-il ses photos ?
- Quelle culture et quelles maladies ciblez-vous, et pourquoi ?
- Quel est le coût d'une erreur ? (traitement inutile, maladie non détectée, perte de récolte)
- Que change concrètement votre outil pour l'agriculteur ?

Étape 2 : Exploration des données et baseline

- Explorer les jeux de données : nombre de classes, déséquilibre, exemples d'images, qualité
- Mettre en place un découpage train / validation / test **sans fuite de données**
- Entraîner un **MLP sur images aplaties** comme baseline. Son rôle est de justifier pourquoi le CNN est nécessaire.

Étape 3 : CNN conçu from scratch

Concevoir et entraîner un petit CNN (convolutions, pooling, dropout). Présenter les courbes de loss et d'accuracy et analyser le surapprentissage éventuel.

Comparez au moins deux variantes de votre architecture (par exemple avec et sans batch normalization, ou avec une profondeur différente) pour montrer l'effet de chaque choix de conception.

Étape 4 : Test de robustesse (cœur du projet)

1. Entraîner sur PlantVillage et tester sur PlantDoc. Mesurer la chute de performance.
2. Proposer et tester des stratégies pour réduire l'écart :
    - Data augmentation (rotations, variations de luminosité, recadrage, changement de fond)
    - Ré-entraînement de votre CNN sur une partie de PlantDoc
    - Entraînement mixte PlantVillage + PlantDoc

Étape 5 : Analyse des erreurs et explicabilité

- Matrice de confusion et rappel par classe
- Exemples mal classés, avec une hypothèse sur la cause de chaque erreur

- **Grad-CAM** : vérifier que le modèle regarde la lésion de la feuille et non le fond de l'image

4. Métriques exigées

L'accuracy seule est **interdite** comme critère de conclusion. Vous devez :

- Rapporter la **précision, le rappel et le F1 par classe**
- Justifier votre métrique principale en fonction du coût des erreurs (une maladie non détectée est souvent plus coûteuse qu'une fausse alerte)
- Présenter systématiquement les résultats **sur données de laboratoire ET locales(optionnel)**

5. Livrables

1. **Notebook reproductible** (Colab ou Kaggle) et **dépôt GitHub documenté** (README, instructions d'exécution, script de téléchargement des données)
2. **Fiche d'impact** (1 page)
3. **Rapport technique** (5 à 8 pages) comprenant obligatoirement une section « Limites et risques »

Structure conseillée du rapport

- Contexte et problème
- Données et préparation
- Modèles et protocole expérimental
- Résultats (laboratoire et local)
- Analyse des erreurs et explicabilité
- Limites, risques et pistes d'amélioration

6. Date limite et envoi

Date limite : le 10/11/2026. L'ensemble des livrables est à envoyer par mail à amadoualwalyndiaye@gmail.com.

Objet du mail : Projet deep learning cohorte 3 AI hub